

Melodia:

Um sistema de recomendação de músicas baseado nos gostos dos usuários

Kenny Jun Takahashi¹, Yuri Nichimura Alves¹

¹Curso de Ciência da Computação Universidade Presbiteriana Mackenzie (UPM) – São Paulo, SP – Brasil

{10396373,10401701}@mackenzista.com.br

Abstract. *With the growth of streaming platforms, music recommendation systems have become essential to offer a personalized experience to the user. This project aims to develop a music recommendation system based on real data obtained by the Spotify API, using Machine Learning techniques. The methodology adopted includes the collection of songs saved by a user, extraction of acoustic characteristics (such as danceability, energy and valence), exploratory analysis of the data and normalization for future application of recommendation models. The system is expected to provide more accurate and relevant music suggestions, contributing to improving the personalized music experience.*

Resumo. *Com o crescimento das plataformas de streaming, sistemas de recomendação musical tornaram-se essenciais para oferecer uma experiência personalizada ao usuário. Este projeto tem como objetivo desenvolver um sistema de recomendação de músicas baseado em dados reais obtidos pela API do Spotify, utilizando técnicas de Machine Learning. A metodologia adotada inclui a coleta de músicas salvas por um usuário, extração de características acústicas (como dançabilidade, energia e valência), análise exploratória dos dados e normalização para futura aplicação de modelos de recomendação. Espera-se que o sistema proporcione sugestões musicais mais precisas e relevantes, contribuindo para aprimorar a experiência musical personalizada.*

Introdução

Contextualização

Com o crescimento exponencial de plataformas de streaming musical, como o Spotify, a quantidade de músicas disponíveis tornou-se praticamente ilimitada. No entanto, essa abundância de escolhas trouxe um novo desafio: como ajudar os usuários a descobrir músicas que realmente se alinhem com seus gostos pessoais?

Os sistemas de recomendação atuais, embora úteis, frequentemente falham em capturar a complexidade das preferências individuais, gerando sugestões genéricas ou repetitivas. Nesse cenário, a inteligência artificial (IA) e o Machine Learning (ML) surgem como ferramentas promissoras para analisar padrões complexos em grandes volumes de dados, como histórico de reprodução e características musicais (ex.: ritmo, energia, tom). A API do Spotify oferece acesso a esses dados, permitindo a criação de modelos mais precisos e personalizados.

Justificativa

A motivação deste projeto baseia-se em três pilares principais:

- Limitações dos sistemas atuais: Algoritmos tradicionais de recomendação muitas vezes priorizam popularidade em vez de relevância individual.
- Oportunidade tecnológica: A API do Spotify fornece dados ricos sobre músicas e usuários, ainda subutilizados em projetos independentes.
- Impacto na experiência do usuário: Recomendações precisas podem aumentar o engajamento e a satisfação em plataformas de streaming.

Além disso, o projeto contribui para o campo acadêmico, explorando técnicas avançadas de ML aplicadas ao entretenimento digital – uma área em crescimento, mas ainda com muitas lacunas de pesquisa.

Objetivo

O propósito deste projeto é desenvolver um sistema de recomendação de músicas baseado nas preferências dos usuários e nas características sonoras das faixas, utilizando dados obtidos via API do Spotify. O sistema busca analisar padrões musicais por meio de técnicas de Machine Learning, promovendo recomendações personalizadas e relevantes.

Opção do Projeto

A escolha por focar no Spotify deve-se a:

- Acessibilidade: Sua API é bem documentada e oferece dados granulares sobre músicas e usuários (com permissão);
- Relevância: É a plataforma de streaming mais popular globalmente, com milhões de playlists públicas para análise;
- Inovação: Possibilita explorar features avançadas não disponíveis em outras APIs;

Descrição do Problema

Os sistemas atuais de recomendação musical enfrentam desafios significativos na era do streaming, onde a abundância de opções dificulta a descoberta de conteúdo relevante. As principais limitações incluem: personalização superficial baseada apenas em popularidade e histórico básico, recomendações repetitivas que criam "bolhas musicais", e dificuldade em adaptar-se às mudanças de preferência dos usuários. Dessa maneira, os problemas se agravam pela alta complexidade dos dados musicais e pela subjetividade na avaliação de qualidade.

Os sistemas existentes falham em integrar adequadamente três dimensões cruciais: comportamento do usuário, características das músicas e contexto de escuta. Além disso, carecem de adaptatividade para evoluir com novas interações e usam métricas que privilegiam engajamento em detrimento da satisfação real.

Estas limitações resultam em frustração por parte de usuários, menor visibilidade para artistas menos conhecidos e estagnação tecnológica no setor. Nosso projeto propõe superar esses obstáculos através de uma abordagem que combina a análise avançada de dados da API do Spotify com modelos de Machine Learning, focando não apenas no "o que é popular", mas no "porquê" determinadas músicas ressoam com cada ouvinte.

Aspectos Éticos e Responsabilidade no Desenvolvimento

Os sistemas de recomendação musical com IA enfrentam desafios éticos complexos que exigem soluções equilibradas. Na privacidade, a conformidade com leis como LGPD e GDPR é fundamental, pois os padrões de escuta revelam aspectos pessoais sensíveis - exigindo anonimização rigorosa e consentimento transparente. O viés algorítmico representa outro obstáculo, com riscos de reforçar artistas populares e marginalizar nichos culturais, problema que demanda técnicas avançadas de Machine Learning justas combinadas com curadoria humana especializada.

A responsabilidade contínua completa este quadro, com a necessidade de testes abrangentes, canais de feedback eficazes e atualizações periódicas para corrigir distorções. A solução ideal integra expertise técnica, ética aplicada e profundo entendimento musical, visando sistemas que enriqueçam a experiência do usuário enquanto respeitam diversidade cultural e privacidade individual. Este equilíbrio delicado entre personalização e responsabilidade social define o futuro ético da recomendação musical automatizada.

Descrição do Dataset

Para o desenvolvimento do sistema de recomendação de músicas, foi utilizado um conjunto de dados extraído da conta pessoal do usuário por meio da API do Spotify. Os dados foram coletados de forma anonimizada, respeitando os princípios éticos de privacidade e segurança das informações.

A coleta dos dados foi realizada utilizando o script `coleta_dados.py`, o qual realiza a autenticação na API do Spotify por meio do protocolo OAuth2. Após a autenticação, o script acessa as músicas salvas na biblioteca do usuário, extraindo características musicais disponibilizadas pela API, tais como:

- danceability: nível de dançabilidade da música;
- energy: intensidade percebida da faixa;
- speechiness: presença de palavras faladas;
- acousticness: probabilidade de a faixa ser acústica;
- instrumentalness: ausência de vocais;
- liveness: probabilidade de a faixa ter sido gravada ao vivo;
- valence: positividade emocional transmitida pela música;
- tempo: tempo (BPM) da faixa;

Adicionalmente, informações como track_name e artist também foram armazenadas. Os dados extraídos foram salvos no arquivo spotify_anonimizado.csv, localizado na pasta dataset/.

A análise exploratória foi realizada no script analise_dados.py. Nessa etapa, utilizamos a biblioteca Pandas para visualizar as primeiras entradas da tabela (head()), bem como gerar estatísticas descritivas (média, desvio padrão, mínimo e máximo). Utilizando Matplotlib e Seaborn, construímos histogramas para analisar a distribuição das variáveis e uma matriz de calor (heatmap) para investigar a correlação entre os atributos sonoros.

Para garantir que todas as variáveis numéricas estivessem na mesma escala, utilizamos o StandardScaler do scikit-learn, que padronizou os dados com média zero e desvio padrão um. O resultado foi um conjunto de dados normalizado, pronto para ser utilizado em algoritmos de machine learning, como o K-Nearest Neighbors (KNN), empregado na fase de recomendação.

Metodologia

O projeto foi dividido em três etapas principais: coleta de dados, análise exploratória e sistema de recomendação.

- Coleta de dados: Utilizou-se a API do Spotify com autenticação via OAuth para acessar até 50 músicas salvas pelo usuário. Foram extraídos dados como nome da faixa, artista e características acústicas da música.
- Anonimização e estruturação: Os dados foram anonimizados e organizados em um arquivo .csv, contendo colunas padronizadas e estruturadas.
- Análise exploratória: Foram geradas estatísticas descritivas, gráficos de distribuição das características sonoras e uma matriz de correlação entre variáveis, permitindo melhor compreensão do perfil musical do usuário.
- Pré-processamento dos dados: As variáveis numéricas foram normalizadas utilizando StandardScaler para que estivessem na mesma escala, facilitando o desempenho dos algoritmos.
- Geração de recomendações: Com os dados tratados, foi implementado o algoritmo de vizinhos mais próximos (KNN) para sugerir músicas semelhantes a uma música escolhida como base. O modelo analisa as distâncias euclidianas entre as faixas normalizadas, retornando aquelas mais similares em termos de perfil acústico.

Resultados

Durante a análise exploratória, foram obtidos dois gráficos principais:

1. Distribuição das características das músicas

Esse gráfico apresenta a frequência das faixas de acordo com suas características sonoras. É possível observar, por exemplo, que a maioria das músicas possui valores medianos a altos para dançabilidade e energia, enquanto características como speechiness e instrumentality aparecem com frequência baixa, indicando predominância de faixas com vocais e estilo mais animado.

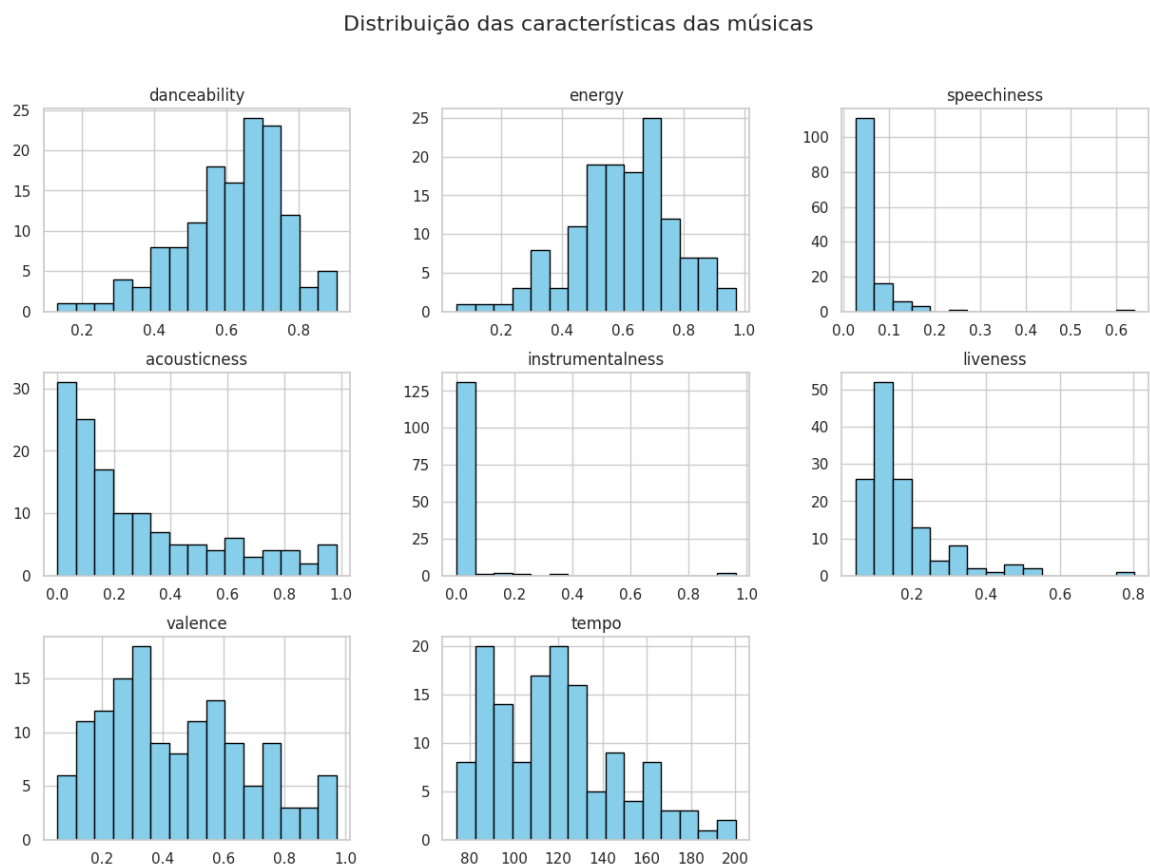


Figura 1. Gráfico de histogramas

2. Matriz de correlação entre características

O heatmap evidencia as relações entre as variáveis numéricas. Destacam-se correlações negativas entre energy e acousticness, o que indica que faixas mais energéticas tendem a ser menos acústicas. Também há correlação moderada entre valence e danceability, sugerindo que músicas dançantes são percebidas como mais positivas.




Figura 2. Heatmap

Após a preparação dos dados, foi implementado o algoritmo K-Nearest Neighbors (KNN) para sugerir músicas semelhantes a uma música base escolhida pelo usuário. A recomendação foi gerada com base nas distâncias entre as características normalizadas das faixas.

Neste experimento, a música "EASY" do artista ARIES foi selecionada como base. O sistema retornou as cinco músicas mais semelhantes, conforme a saída abaixo:

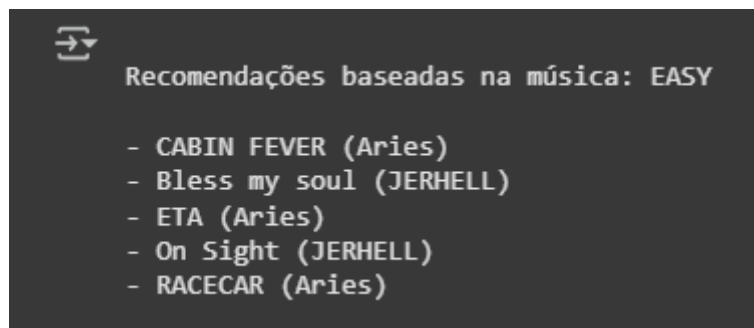


Figura 3. Recomendações geradas

Essas faixas apresentaram forte similaridade nos atributos acústicos em relação à faixa escolhida, demonstrando a eficiência do sistema na recomendação personalizada.

Conclusão

O projeto mostrou na prática que é possível usar a API do Spotify para coletar dados reais de músicas e, a partir disso, aplicar técnicas de pré-processamento e machine learning para criar um sistema de recomendação. O uso do algoritmo KNN funcionou bem para identificar músicas parecidas com base em várias características sonoras, como dançabilidade, energia e valência. Com isso, conseguimos gerar recomendações personalizadas que fazem sentido para o gosto do usuário. Mesmo sendo uma versão inicial, o sistema pode ser melhorado no futuro com algoritmos mais avançados, como redes neurais ou abordagens híbridas, para deixar as sugestões ainda mais precisas e adaptadas a diferentes perfis musicais.

Endereços

link do GitHub: <https://github.com/junntk/Projeto-IA---Melodia>

link do vídeo no Youtube:

Bibliografia

Alkhovik, R. (2024). “O que é a API da Web do Spotify: automatizando análises de música e experiências do usuário”. Disponível em: <https://latenode.com/pt-br/blog/what-is-the-spotify-web-api-automating-music-analytics-and-user-experiences>

Ateliê Software. (2024). K-Nearest Neighbors (KNN): entendendo seu funcionamento e construindo do zero. Disponível em: <https://share.atelie.software/k-nearest-neighbors-knn-entendo-o-seu-funcionamento-e-o-construindo-do-zero-a21b022acd6f>

Awari. (2024). KNN Inteligência Artificial: entendendo o algoritmo de aprendizado de máquina K-Nearest Neighbors. Disponível em: <https://awari.com.br/knn-inteligencia-artificial-entendendo-o-algoritmo-de-aprendizado-de-maquina-k-nearest-neighbors/>

Ciencia e Dados. (2024). Algoritmos de Machine Learning: K-Nearest Neighbors (KNN). Disponível em: <https://cienciaedados.com.br/algoritmos-de-machine-learning-k-nearest-neighbors-knn/>

Didática Tech. (2024). O que é e como funciona o algoritmo KNN. Disponível em: <https://didatica.tech/o-que-e-e-como-funciona-o-algoritmo-knn/>

Loyola, N.; Macohin, A.; Barbosa, I.; Fagundes, V.; Graça, F. (2023). “Ética na IA”. Disponível em: <https://www.serpro.gov.br/menu/noticias/noticias-2023/etica-na-ia>

Moraes, H.; Szentmiklósy, J. (2024). “Desafios éticos do uso de IA para o tratamento de dados pessoais”. Disponível em: <https://www.migalhas.com.br/depeso/405003/desafios-eticos-do-uso-de-ia-para-o-tratamento-de-dados-pessoais>

Nardon, B. (2023). “Inteligência Artificial: oportunidades e desafios éticos para uma sociedade que emerge”. Disponível em: <https://mittechreview.com.br/inteligencia-artificial-oportunidades-e-desafios-eticos-para-uma-sociedade-que-emerge>

Oliveira, M. (2024). “Como Usar a API Web do Spotify | Integre Facilmente com o Spotify”. Disponível em: <https://apidog.com/pt/blog/spotify-web-api/>

Taraves, J. (2024). “Quais são os desafios éticos da Inteligência Artificial?”. Disponível em: <https://www.mindtek.com.br/2024/12/quais-sao-os-desafios-eticos-da-inteligencia-artificial/>

UNICEP. (2024). “Inteligência Artificial e Ética: Conheça o impacto ético da IA na sociedade.”. Disponível em: <https://www.unicep.edu.br/post/inteligencia-artificial-e-etica-conheca-o-impacto-etico-da-ia-na-sociedade>